

Intelligenza Artificiale

UniVR - Dipartimento di Informatica

Fabio Irimie

1° Semestre 2025/2026

Indice

1	Introduzione	2
1.1	Tipi di intelligenza artificiale	2
1.1.1	Autonomous agents	2
1.1.2	Data analysis	2
1.1.3	Machine Learning	2
1.1.4	Time series analysis	3
1.1.5	Intelligent Agents	3
1.2	Markov Decision Process (MDP)	3
1.3	Generative AI	4
2	Agenti e ambiente	4
2.1	Razionalità	5
2.2	PEAS	6
3	Tipi di ambienti	7
3.1	Agenti di problem solving	7
3.2	Algoritmo tree search	9
3.2.1	Stato e nodo	9
3.2.2	Tree search generale	9

1 Introduzione

Nel 1950 Alan Turing pubblica un articolo intitolato "Computing Machinery and Intelligence" in cui propone un esperimento per determinare se una macchina può essere considerata intelligente. L'esperimento, noto come "test di Turing", coinvolge un interrogatore umano che comunica con due entità nascoste: una macchina e un essere umano. L'interrogatore deve fare domande a entrambe le entità e, basandosi sulle risposte, deve determinare quale delle due è la macchina. Se l'interrogatore non riesce a distinguere tra le risposte della macchina e quelle dell'essere umano, la macchina è considerata intelligente.

In futuro l'attenzione si è spostata sulla ricerca di metodi per risolvere problemi che richiedono intelligenza umana, utilizzando algoritmi e modelli matematici fino ad arrivare alle reti neurali e intelligenza artificiale.

Definizione 1.1. L'intelligenza artificiale è una disciplina che studia come **simulare** l'intelligenza umana in scenari complessi

1.1 Tipi di intelligenza artificiale

1.1.1 Autonomous agents

Sono sistemi che percepiscono l'ambiente e agiscono in modo autonomo per raggiungere obiettivi specifici.

1.1.2 Data analysis

Utilizzo di algoritmi per analizzare grandi quantità di dati e estrarre informazioni utili e correlazioni complesse.

1.1.3 Machine Learning

È lo sviluppo di algoritmi che permettono a dei modelli di apprendere dai dati di esempio e migliorare le loro prestazioni nel tempo senza essere esplicitamente programmati. Ad esempio riconoscimento di immagini.

L'apprendimento automatico è diviso in tre categorie principali:

- **Unsupervised learning:** il modello viene addestrato su un insieme di dati non etichettati, dove l'obiettivo è scoprire strutture nascoste o pattern nei dati senza avere risposte corrette predefinite.
- **Supervised learning:** il modello viene addestrato su un insieme di dati etichettati, dove ogni esempio di input è associato a una risposta corretta. L'obiettivo è che il modello impari a mappare gli input alle risposte corrette.
- **Reinforced learning:** il modello impara attraverso interazioni con l'ambiente, ricevendo ricompense o penalità in base alle azioni intraprese. L'obiettivo è massimizzare la ricompensa totale nel tempo.

1.1.4 Time series analysis

L'analisi delle serie temporali è un'area dell'apprendimento automatico che si concentra sull'analisi di dati collezionati nel tempo. Le serie temporali sono sequenze di dati misurati a intervalli regolari, come temperatura giornaliera, prezzi delle azioni o dati di vendita mensili. L'obiettivo dell'analisi delle serie temporali è identificare pattern, tendenze e stagionalità nei dati per fare previsioni future.

Gli approcci comuni per l'analisi delle serie temporali includono:

- **Riconoscimento di anomalie e cause:** è un processo di identificazione di dati o eventi che si discostano significativamente dal comportamento normale o atteso. Queste anomalie possono indicare problemi, errori o situazioni insolite che richiedono attenzione.
- **Generative transformers:** sono una classe di modelli che permettono di predire il prossimo elemento in una sequenza di dati partendo dagli elementi precedenti, come ad esempio la parola successiva in una frase o il pixel successivo in un'immagine. Si sfrutta il concetto di **attenzione** per pesare l'importanza relativa delle diverse parti della sequenza di input durante la generazione dell'output.

1.1.5 Intelligent Agents

Un agente intelligente è un sistema che percepisce l'ambiente circostante attraverso sensori e agisce su l'ambiente per raggiungere un obiettivo specifico. Gli elementi chiave di un agente intelligente includono:

- **Performance measure:** misura il successo dell'agente nel raggiungere i suoi obiettivi
- **Rationality:** l'agente deve agire in modo da massimizzare la sua performance measure attesa

1.2 Markov Decision Process (MDP)

Un MDP è un modello matematico utilizzato per rappresentare problemi di decisione sequenziali. Gli elementi principali sono:

- **State:** rappresenta l'ambiente in un dato momento
- **Actions:** insieme delle azioni che l'agente può intraprendere
- **Transition model:** effetto che le azioni hanno sull'ambiente (potrebbero essere parzialmente incognite)

$$T : (\text{state}, \text{action}) \rightarrow \text{next_state}$$

- **Reward:** valore **immediato** dell'esecuzione di un'azione

$$R : (\text{state}, \text{action}, \text{next_state}) \rightarrow \text{real_number}$$

- **Policy:** strategia che l'agente utilizza per decidere quale azione intraprendere in ogni stato con l'obiettivo di massimizzare la ricompensa totale attesa nel tempo

$$\pi : (\text{state}) \rightarrow \text{action}$$

1.3 Generative AI

L'intelligenza artificiale generativa si riferisce a una classe di modelli di intelligenza artificiale che sono in grado di generare nuovi contenuti, come testo, immagini, musica o video, a partire da dati di addestramento. Questi modelli hanno miliardi di parametri e sono **preaddestrati** su grandi quantità di dati. In sostanza questi modelli "predicono il futuro" basandosi sui dati su cui sono stati addestrati e un **prompt** (input dell'utente).

2 Agenti e ambiente

Gli agenti includono umani, robot, softbot, termostati ecc... La funzione dell'agente mappa lo storico di percezioni in azioni:

$$f : \mathcal{P}^* \mapsto \mathcal{A}$$

Il programma dell'agente è eseguito su architettura fisica per produrre la funzione f .

Esempio 2.1. Un esempio potrebbe essere un insieme di stanze $\{A, B\}$ e un robot aspirapolvere che può percepire la sua posizione e il contenuto della stanza. L'agente potrebbe quindi percepire $[A, \text{Sporco}]$ se ci fosse dello sporco nella stanza A. Le azioni potrebbero essere di movimento o pulizia. Tutto questo dipende dalla sequenza di percezioni, ad esempio in una tabella:

Percezione	Azione
$[A, \text{Pulito}]$	Vai a B
$[A, \text{Sporco}]$	Pulisci
$[B, \text{Pulito}]$	Vai ad A
$[B, \text{Sporco}]$	Pulisci
$[A, \text{Pulito}], [A, \text{Pulito}]$	Vai a B
$[A, \text{Pulito}], [A, \text{Sporco}]$	Pulisci

Tabella 1: Esempio di tabella di percezioni e azioni

Non possiamo dire se questa è una funzione corretta perchè non abbiamo una **performance measure** che ci dica se l'agente sta facendo un buon lavoro.

Definizione 2.1. Se un agente ha $|\mathcal{P}|$ possibili percezioni, allora al tempo T avrà:

$$\sum_{t=1}^T |\mathcal{P}|^t$$

Se lo storico di percezioni è irrilevante, cioè se ad ogni percezione è associata un'azione la funzione viene chiamata **Reflex**.

2.1 Razionalità

Per definire l'intelligenza di un agente si utilizza una misura di performance che valuta la sequenza di percezioni.

Esempio 2.2. Tornando all'esempio del robot aspirapolvere si potrebbero assegnare i seguenti punteggi:

- Un punto per ogni stanza pulita per ogni unità di tempo
- Meno un punto per ogni mossa
- Penalizzazione per ogni stanza sporca

Esempio 2.3. Un altro esempio è il seguente ambiente:

- Ci sono 3 stanze (A, B, C) e due robot (r_1, r_2)
- r_1 può sorvegliare solo A e B e r_2 solo B e C
- r_1 inizia dalla stanza A e r_2 dalla C
- Il tempo di percorrenza tra le stanze è 0
- Performance measure: minimizza il tempo in cui una stanza non è sorvegliata, cioè il tempo totale in cui una stanza non è visitata da nessun robot

Un possibile comportamento razionale potrebbe essere il seguente (alternata):

Stato	A	B	C	Tempo
[A, C]	0	1	0	1
[B, C]	1	0	0	2
[A, C]	0	1	0	3
[A, B]	0	0	1	4
Average idleness	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	Tot: $\frac{1}{3}$

Un altro comportamento potrebbe essere (fissata):

Stato	A	B	C	Tempo
[A, C]	0	1	0	1
[B, C]	1	0	0	2
[A, C]	0	1	0	3
[B, C]	1	0	0	4
Average idleness	$\frac{1}{2}$	$\frac{1}{2}$	0	Tot: $\frac{1}{3}$

Entrambi i comportamenti hanno la stessa performance measure, ma il primo è migliore del secondo perchè penalizza meno una singola stanza rispetto alle

altre. Per capirlo bisogna non solo minimizzare la performance measure, ma anche minimizzare la varianza.

2.2 PEAS

Per progettare un agente intelligente bisogna definire l'ambiente in cui opera:

- **Performance measure:** come viene valutato il successo dell'agente
- **Environment:** il contesto in cui l'agente opera
- **Actuators:** i mezzi attraverso cui l'agente agisce sull'ambiente
- **Sensors:** i mezzi attraverso cui l'agente percepisce l'ambiente

Esempio 2.4. Prendiamo ad esempio un taxi automatico, il PEAS potrebbe essere:

- Performance measure:
 - Soddisfazione del cliente
 - Sicurezza
 - Efficienza del carburante
 - Rispetto delle leggi stradali
- Environment:
 - Traffico stradale
 - Condizioni meteorologiche
 - Segnali stradali
 - Pedoni e altri veicoli
- Actuators:
 - Volante
 - Acceleratore
 - Freni
 - Indicatori di direzione
- Sensors:
 - Telecamere
 - Lidar
 - Radar
 - Sensori di velocità
 - GPS

3 Tipi di ambienti

Gli ambienti possono essere classificati in base a diverse caratteristiche:

- **Osservabile:** se l'agente può percepire completamente lo stato dell'ambiente in ogni momento
- **Deterministico:** se l'azione dell'agente determina in modo univoco il prossimo stato dell'ambiente
- **Episodico:** se l'esperienza dell'agente è divisa in episodi indipendenti, cioè l'azione in un episodio non influisce sugli episodi successivi
- **Statico:** se l'ambiente non cambia mentre l'agente sta prendendo una decisione
- **Discreto:** se l'insieme di stati, azioni e percezioni è finito o numerabile
- **Singolo agente:** se l'agente opera da solo nell'ambiente senza la presenza di altri agenti

Esempio 3.1. Prendiamo ad esempio i seguenti ambienti provando a classificarli:

	Crossword	Robo-selector	Poker	Taxi
Osservabile	Sì	Parziale	Parziale	Parziale
Deterministico	Sì	No	No	No
Episodico	No	Sì	No	No
Statico	Sì	No	Sì	No
Discreto	Sì	No	Sì	No
Singolo agente	Sì	Sì	No	No

Il tipo di ambiente cambia radicalmente la soluzione del problema:

- **Deterministico, completamente osservabile:** Single-state problem
- **Completamente non osservabile:** Conformant problem, l'agente non sa in che stato si trova, ma potrebbe trovare una soluzione
- **Non deterministico e/o parzialmente osservabile:** Contingency problem, l'agente deve prevedere le possibili situazioni future e agire di conseguenza
- **Spazio degli stati sconosciuto:** Exploration problem, l'agente deve esplorare l'ambiente per scoprire gli stati e le azioni disponibili

3.1 Agenti di problem solving

È una forma ristretta di agenti che formulato un problema e un obiettivo partendo da uno stato cerca una soluzione ignorando le percezioni, siccome ci si trova in un single-state problem. Questo si chiama Offline problem solving perchè l'agente ha completa conoscenza dell'ambiente. Online problem solving è quando l'agente non ha completa conoscenza dell'ambiente.

Esempio 3.2. Il seguente è un esempio di problem solving agent:

```
1 function Simple-Problem-Solving-Agent(percept) returns action
2   static: seq, an action sequence, initially empty
3           state, some description of the current world state
4           goal, a goal, initially null
5           problem, a problem formulation
6
7   state <- Update-State(state, percept)
8
9   if seq is empty then
10     goal <- Formulate-Goal(state)
11     problem <- Formulate-Problem(state, goal)
12     seq <- Search( problem)
13
14   action <- First(seq)
15   seq <- Rest(seq)
16   return action
17
```

Esempio 3.3. Consideriamo il problema "Vacanze in Romania". Bisogna formulare un viaggio da Arad a Bucarest sapendo che l'aereo parte domani.

- **Goal:** Arrivare a Bucarest
- **Formulazione del problema:**
 - Stati: città della Romania
 - Azioni: volare tra le città
- **Soluzione:** Sequenza di città

Si potrebbe usare una mappa per trovare il percorso più breve (visione completa del mondo) e trovare una soluzione ottimale. Questo problema è definito da 4 componenti:

- **Stato iniziale:** ad esempio "ad Arad"
- **Funzione di transizione:** insieme di coppie (stato, azione) che mappano uno stato in un altro, ad esempio:

$$S(A) = \{\langle \text{Arad} \rightarrow \text{Zerind}, \text{Zerind} \rangle, \dots\}$$

- **Test dell'obiettivo:** una funzione che verifica se lo stato corrente soddisfa l'obiettivo, ad esempio:

$$\text{Goal-Test}(s) = \begin{cases} \text{true} & \text{se } s = \text{Bucarest} \\ \text{false} & \text{altrimenti} \end{cases}$$

- **Path cost:** è una funzione che assegna un costo (additivo) a ogni azione, ad esempio la somma di distanze o il numero di azioni:

$$c(x, a, y) \geq 0$$

- **Soluzione:** Una sequenza di azioni che portano dallo stato iniziale allo stato obiettivo.

3.2 Algoritmo tree search

Un algoritmo di ricerca ad albero esplora lo spazio degli stati partendo dallo stato iniziale e generando nuovi stati (successori) applicando le azioni disponibili, cioè **espandendo** gli stati:

```

1 function Tree-Search(problem, strategy) function Tree-Search(
  problem, strategy) returns a solution, or failure
2 initialize the search tree using the initial state of problem
3 loop do
4   if no candidates for expansion then return failure
5   choose a leaf node for expansion according to strategy
6   if node contains a goal state then return the solution
7   else add successor nodes to the search tree (expansion)
8   end
9   returns a solution, or failure
9   initialize the search tree using the initial state of problem
10  loop do
11    if no candidates for expansion then return failure
12    choose a leaf node for expansion according to strategy
13    if node contains a goal state then return the solution
14    else add successor nodes to the search tree (expansion)
15  end

```

3.2.1 Stato e nodo

Stato e nodo non sono la stessa cosa, infatti:

- **Stato:** rappresenta una configurazione dell'ambiente
- **Nodo:** è una struttura dati che costituisce una parte dell'albero di ricerca e include informazioni aggiuntive come il genitore, l'azione che ha portato a quello stato, il costo del percorso o la profondità nell'albero, ecc...

3.2.2 Tree search generale

Espandere un nodo significa generare i suoi figli, cioè i nodi successori e tutti i nodi non esplorati sono chiamati **frontiera**.

```

1 function Tree-Search( problem, frontier) returns a solution, or
  failure
2   frontier <- Insert(Make-Node(problem.Initial-State))
3   while not IsEmpty(frontier) do
4     node <- Pop(frontier)
5     if problem.Goal-Test(node.State) then return node
6     frontier <- InsertAll(Expand(node, problem))
7   end loop
8   return failure

```

La strategia è quella di scegliere l'ordine in cui i nodi vengono espansi, cioè come viene gestita la frontiera. Le strategie sono valutate in base a:

- **Completezza:** se garantisce di trovare una soluzione quando esiste
- **Complessità di tempo:** numero di nodi generati o espansi
- **Complessità di spazio:** numero massimo di nodi memorizzati in memoria
- **Ottimalità:** se garantisce di trovare la soluzione migliore